



FACULDADE DE
CIÊNCIAS E TECNOLOGIA
UNIVERSIDADE DE
COIMBRA

Departamento de Engenharia Informática

Fundamentos de Inteligência Artificial
Introdução à Inteligência Artificial
2021/2022 - 2º Semestre

Trabalho Prático N^o2:
The Slow & The Calm:
Darwin's Edition

Nota: A fraude denota uma grave falta de ética e constitui um comportamento inadmissível num estudante do ensino superior e futuro profissional licenciado. Qualquer tentativa de fraude levará à anulação da componente prática tanto do facilitador como do prevaricador, independentemente de acções disciplinares adicionais a que haja lugar nos termos da legislação em vigor. Caso haja recurso a material não original, as **fontes** devem estar explicitamente indicadas.

1 Introdução

Fascinado pela forma como a Natureza resolve os problemas que encontra, o Homem usa-a frequentemente como fonte de inspiração para desenvolver soluções computacionais para problemas difíceis. É neste sentido que surgem os Algoritmos Evolucionários (AE), que são modelos computacionais inspirados na Teoria da Selecção Natural de Charles Darwin, e nos princípios de herança genética descobertos por Gregor Mendel. Estes métodos tem sido aplicados com sucesso em diversas áreas, desde optimização até ao desenho automático de antenas para satélites.

O objectivo deste trabalho passa por desenvolver as componentes de um AE para desenhar um veículo motorizado. Para isso, iremos recorrer a um simulador virtual¹, que permite avaliar o desempenho do veículo em vários cenários, nomeadamente deslocar-se em percursos com buracos, e em percursos com subidas.

O principal objectivo é que veículo seja capaz de chegar o mais longe possível no percurso onde é inserido. A Figura 1 mostra um exemplo do ambiente ambiente de simulação.

2 Enunciado

Este trabalho prático tem como objectivo principal a aquisição de competências relacionadas com a análise, desenvolvimento, implementação e teste de agentes adaptativos.

Assim, pretende-se desenvolver uma Algoritmo Evolucionário (AE) que permite o desenho de veículos para completar um conjunto de percursos. O AE irá evoluir um conjunto de parâmetros relacionados com a estrutura do veículos (e.g., número de rodas, posição das rodas, raio, etc.) de forma a melhorar a sua performance ao longo do tempo.

Os nossos veículos são compostos por:

1. 8 vectores com um tamanho máximo de 64m, com um ângulo que é calculado a partir do centro do carro;
2. De 0 e 15 rodas:
 - (a) Com um raio entre 0 e 3;
 - (b) Posição da roda no carro;

¹O simulador é baseado na Framework GeneticSharp desenvolvida por Diego Giacomelli

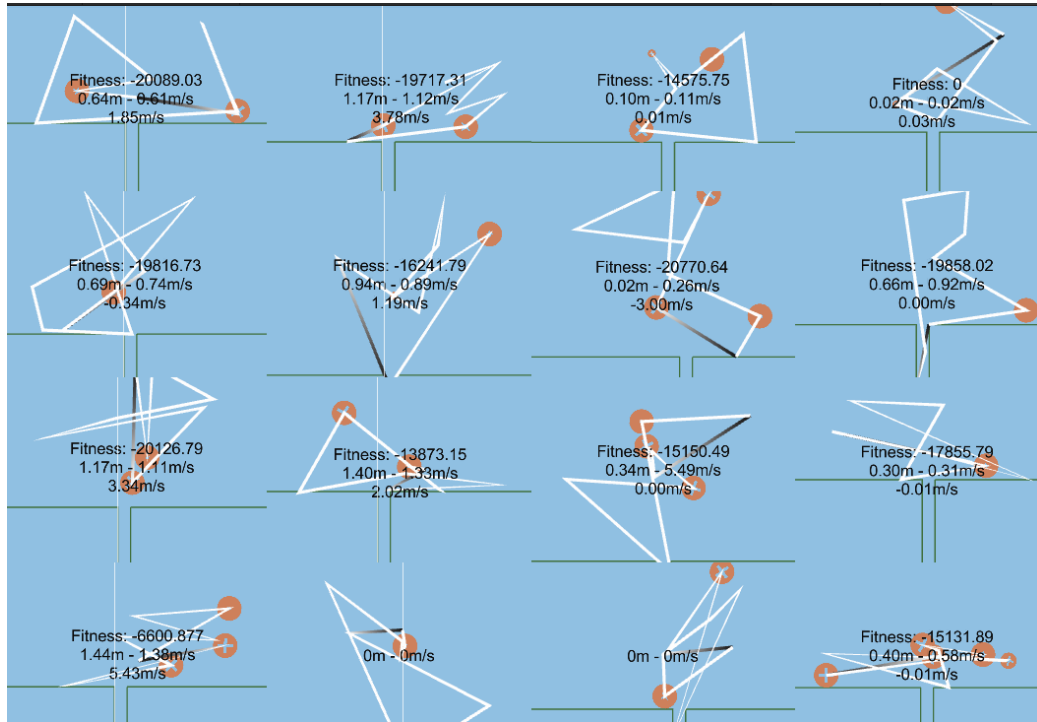


Figura 1: Exemplo do ambiente de simulação.

Tanto as rodas como os vectores tem uma massa associada, pelo que o seu tamanho tem influencia no peso do carro.

Para representar o veículo acima descrito no nosso AE, vamos utilizar um cromossoma binário com a seguinte estrutura:

1. Um número real que corresponde ao tamanho de cada vector representado utilizando 7 bits;
2. Um número real que corresponde ao ângulo de cada vector representado por 9 bits;
3. Um número inteiro que corresponde ao índice do vector onde deverá ser colocada a roda representado por 7 bits;
4. Um número real que corresponde ao raio de cada roda representado por 4 bits;

No total, necessitamos de 27 bits para descrever a estrutura acima descrita. Como o nosso veículo é composto por 8 vectores, temos de a repetir 8 vezes, o que resulta num cromossoma com tamanho 216. Um exemplo do

cromossoma é apresentado abaixo, bem como o fenótipo associado, i.e., o veículo (Fig. 2).

Listing 1: Genótipo

```
0,1,1,0,0,0,0,0,0,0,0,0,0,0,1,1,0,1,1,0,0,1,0,1,1,1,0,0,
0,0,0,0,1,1,1,1,0,0,0,0,0,0,1,1,1,0,0,0,0,1,0,0,1,0,0,
1,0,1,0,0,1,0,1,1,0,1,0,0,0,1,0,0,1,0,0,0,1,0,0,1,0,
1,0,1,0,0,1,0,0,1,0,0,1,1,0,0,1,0,0,1,1,0,1,1,0,1,1,
0,1,0,1,1,1,1,0,1,1,1,0,0,1,1,1,1,0,0,1,0,0,1,1,1,1,
1,0,0,0,0,1,1,1,0,0,0,1,0,0,0,1,0,0,1,0,0,0,0,0,0,0,
0,0,0,0,0,0,0,0,0,0,1,1,0,0,1,0,1,0,1,1,0,1,1,1,0,0,1,
1,0,1,0,0,1,0,0,0,0,0,1,0,1,1,0,1,1,0,0,0,1,0,0,0,0,
0,1,0,0,0,1,1,0
```




Figura 2: Fenótipo

De forma a permitir avaliar a qualidade de cada veículo são retiradas várias informações do ambiente de simulação, nomeadamente:

- Distância máxima percorrida;
- Velocidade Máxima atingida;
- Número de rodas;
- Massa do carro;
- Conseguiu chegar ao fim do percurso.

O presente trabalho prático encontra-se dividido em 2 metas distintas:

1. Meta 1 – Modelação e desenvolvimento do Algoritmo Genético.
2. Meta 2 – Experimentação e análise.

2.1 Meta 1 – Modelação e desenvolvimento do Algoritmo Genético

A representação escolhida, os operadores genéticos, os mecanismos de selecção, a atribuição de aptidão (*fitness*), são componentes essenciais para o bom funcionamento de um algoritmo genético. Desta forma, a etapa de **modelação** desempenha um papel fundamental no sucesso do seu algoritmo. Relativamente à representação de cada veículo, i.e., solução, o código fornecido considera que cada cromossoma é uma lista de 0 e 1's. No entanto, terá de desenvolver as restantes funcionalidades básicas do Algoritmo Genético, alterando os ficheiros que se encontram na pasta `EvolvingCars/Assets/EvolvingCars/TP2/`:

Recombinação Deve desenvolver o operador de recombinação de **1-ponto**, descrito pelo Algoritmo 1. Para isso deverá editar o ficheiro `Meta1/SinglePointCrossover.cs`;

Mutação Desenvolver o operador de mutação de *bit-flip* descrito pelo Algoritmo 2. Para isso deverá editar o ficheiro `Meta1/SinglePointMutation.cs`;

Seleccção de Pais Deve implementar o mecanismo de **selecção por torneio**, descrito pelo Algoritmo 3. **Lembre-se que é um problema de maximização**. Para isso deverá editar o ficheiro `Meta1/Tournament.cs`;

Seleccção de Sobreviventes Deve implementar o mecanismo de **Elitismo**, descrito pelo Algoritmo 4. Para isso deverá editar o ficheiro `Meta1/Elitism.cs`;

Parameterização Os parâmetros do algoritmo evolucionário – p.ex. especificar a probabilidade de mutação por gene, probabilidade de recombinação, tamanho do torneio, deverão ser configurados e alterados no ficheiro `GeneticAlgorithmConfigurations.cs`;

Aptidão A aptidão de um indivíduo está relacionada com a capacidade dos veículos conseguirem chegar o mais longe possível nos cenários onde são inseridos. É por isso um **componente essencial** ao sucesso do algoritmo, e encontra-se programada no ficheiro `CarFitness.cs`. Devem ser exploradas várias funções de aptidão, tendo em conta o conjunto de informações do ambiente. Para conseguir desenvolver a sua função de aptidão terá ao dispôr, em cada simulação, as seguintes informações:

1. `MaxDistance` - Distância máxima percorrida pelo veículo;

2. MaxDistanceTime - Tempo (em segundos) que o veículo demorou a percorrer a distância máxima;
3. MaxVelocity - Velocidade máxima atingida pelo veículo;
4. NumberOfWheels - Número de rodas que foram utilizadas pelo veículo;
5. CarMass - Peso do veículo;
6. IsRoadComplete - Indica se o veículo completou o cenário, isto é, se chegou ao fim da estrada. Tem o valor 1 se completar o cenário, e 0 caso contrário.

```

1 Function SinglePointCrossover(parents):
2   i  $\leftarrow$  0 ;
3   if RandomizationProvider.Current.GetDouble()  $\leq$ 
      crossoverProbability then
4     cutPoint = RandomizationProvider.Current.GetInt(1,
      parent1.Length)
5     for i < cutPoint do
6       offspring1.ReplaceGene(i, parent2.GetGene(i))
7       offspring2.ReplaceGene(i, parent1.GetGene(i))
8       i  $\leftarrow$  i + 1
9     end
10  end

```

Algoritmo 1: Pseudocódigo do Algoritmo de Single Point Crossover. As funções RandomizationProvider.Current.GetDouble e RandomizationProvider.Current.GetInt já se encontram implementadas, e devem ser chamadas de forma como se encontra no pseudocódigo.

```

1 Function SinglePointMutation(chromosome, probability):
2   i  $\leftarrow$  0
3   for i < chromosome.Length do
4     if RandomizationProvider.Current.GetDouble()  $\leq$  probability
5       then
6         geneValue = chromosome.GetGene(i).Value
7         if geneValue == 1 then
8           | chromosome.ReplaceGene(i, new Gene(0))
9         else
10          | chromosome.ReplaceGene(i, new Gene(1))
11        end
12      i  $\leftarrow$  i + 1
13    end

```

Algoritmo 2: Pseudocódigo do Algoritmo de Single Point Mutation. A função *RandomizationProvider.Current.GetDouble* já se encontra implementada, e devem ser chamada de forma como se encontra no pseudocódigo.

```

1 Function TournamentSelection(number, generation):
2   parents  $\leftarrow$  []
3   i  $\leftarrow$  0
4   for i < number do
5     randomIndexes =
      RandomizationProvider.Current.GetUniqueInts(Size, 0,
      population.Count);
6     winner  $\leftarrow$  null
7     winnerFitness = -1
8     for k < Size do
9       /* Maximização */
10      individualIndex  $\leftarrow$  randomIndexes[k]
11      if (winner == null) or population[individualIndex].Fitness
        > winnerFitness then
12        winner  $\leftarrow$  population[individualIndex]
13        winnerFitness  $\leftarrow$  population[individualIndex].Fitness
14      end
15      k  $\leftarrow$  k + 1
16    end
17    parents.Add(winner)
18    i  $\leftarrow$  i + 1
19  end

```

Algoritmo 3: Pseudocódigo do Algoritmo de Selecção por Torneio. Este algoritmo permite seleccionar o melhor indivíduo num torneio de *Size* indivíduos, e adicionar à lista de progenitores. A função `RandomizationProvider.Current.GetUniqueInts` já se encontra implementada, e devem ser chamada de forma como se encontra no pseudocódigo.

```

1 Function Elitism(population, offspring, parents):
2   i  $\leftarrow$  0
3   for i < eliteSize do
4     offspring[i]  $\leftarrow$  old_population[i]
5     i  $\leftarrow$  i + 1
6   end

```

Algoritmo 4: Pseudocódigo do Algoritmo de Selecção de Sobreviventes com Elitismo.

	Mutação	Elitismo	Torneio	Crossover	Número Gerações
Experiência 1	0.05	0	5	0.9	30
Experiência 2	0.2				
Experiência 3	0.05	2	5	0.9	30
Experiência 4	0.2				
Experiência 5	0.05		2		

Tabela 1: Experiências a realizar no cenário **GapRoad**. Note que, para cada experiência deverá realizar 3 execuções da mesma.

Após implementadas, é vital **testar** as funcionalidades do algoritmo evolucionário por forma a garantir o seu bom funcionamento. Para isso faça uso do cenário **GapRoad**. Aqui deverá conseguir desenvolver uma função de fitness que permita ao algoritmo evolucionário encontrar um veículo capaz de chegar ao fim da estrada.

2.2 Meta 2 – Experimentação e análise

Nesta meta deve utilizar a aplicação desenvolvida para encontrar uma solução para os ambientes disponibilizados. Deve utilizar o código desenvolvido na meta anterior para evoluir os veículos. Os veículos podem ser evoluídos usando diferentes funções de aptidão adoptando assim comportamentos distintos. Deve criar diversas funções de aptidão utilizando a informação disponibilizada pelo ambiente, e tentando optimizar o veículo tendo em conta diferentes parâmetros. Durante a evolução, o genótipo dos melhores veículos é guardado na pasta do projeto. Deve usar os cenários “Evaluation” para validar e testar os veículos evoluídos.

Dada a natureza estocástica das abordagens evolucionárias não é possível tirar conclusões a partir de uma única execução. Para cada combinação de parâmetros deverá realizar, pelo menos, **3** repetições da experiência para que a comparação efectuada tenha significado estatístico. **Desta forma, é importante reservar o tempo adequado para esta meta.**

Deve conduzir um conjunto alargado de experiências no cenário **GapRoad** considerando, de forma sistemática, diferentes combinações de parâmetros, nomeadamente as combinações apresentadas nas Tabela 1.

Não basta enumerar resultados experimentais, deve fazer uma análise dos mesmos procurando explicar as diferenças encontradas e os comportamentos apresentados. Para o auxiliar nesta tarefa, o simulador guarda um conjunto de informações sobre o processo evolucionário na pasta com o nome **Results** que se encontra dentro da pasta projecto Unity. Em concreto, tem acesso a

2 ficheiros:

- **EvolutionLog.csv** - Guarda, a cada geração, as seguintes informações:
 - **Generation**: Número da geração;
 - **BestFitness**: Qualidade do melhor indivíduo;
 - **AverageFitnessPopulation**: Qualidade média da população;
 - **BestMaxDistance**: Distância máxima percorrida pelo melhor indivíduo;
 - **BestMaxDistanceTime**: Tempo que o melhor indivíduo demorou a percorrer a distância máxima;
 - **BestNumberOfWheels**: Número de rodas do melhor indivíduo;
 - **BestCarMass**: Massa do melhor indivíduo;
 - **BestIsRoadComplete**: Indica se o melhor indivíduo conseguiu, ou não, chegar ao fim da estrada.
- **OverallBestGenotype.txt** - Genótipo do melhor indivíduo. Este ficheiro poderá ser carregado nos cenários **EvaluationGap** ou **EvaluationHill** de forma a verificar o comportamento do indivíduo.

Após a avaliação das componentes do algoritmo genético deverá escolher a(s) melhor(es) combinações e aplicar as mesmas no cenário **HillRoad**, de forma a encontrar um veículo que o permita resolver.

3 Datas e Modo de Entrega

Os grupos têm uma dimensão máxima de 3 alunos. A defesa é obrigatória, bem como a presença de todos os elementos do grupo na mesma.

A entrega da meta 1 é opcional, chama-se no entanto a atenção dos alunos para a importância de concluir atempadamente esta meta. Para efeitos de nota apenas será considerada a entrega final e a defesa.

3.1 Meta 1 – Modelação e desenvolvimento

Material a entregar:

- Scripts onde implementaram e/ou alteraram código, que deve estar devidamente comentado.

- Um breve documento (max. 3 páginas), em formato pdf, com a seguinte informação:
 - Identificação dos elementos do grupo (Nomes, Números de Estudante, e-mails, Turma(s) Prática(s))
 - Informação pertinente relativamente a esta meta

Modo de Entrega:

Entrega electrónica através do Inforestudante.

Data Limite: 01 de Maio de 2022

3.2 Meta 2 – Experimentação e análise

Tal como indicado anteriormente, esta entrega será a única que tem um impacto directo na nota. O relatório deve conter informação relativa a **todo** o trabalho realizado. Ou seja, o trabalho realizado no âmbito das metas 1 e 2 deve ser **inteiramente descrito**, por forma a possibilitar a avaliação.

Material a entregar:

- Scripts onde implementaram e/ou alteraram código, que deve estar devidamente comentado.
- Um relatório (max. 20 páginas), em formato pdf, com a seguinte informação:
 - Identificação dos elementos do grupo (Nomes, Números de Estudante, e-mails, Turma(s) Prática(s))
 - Informação pertinente relativamente à globalidade do trabalho realizado

Num trabalho desta natureza o relatório assume um papel importante. Deve ter o cuidado de descrever detalhadamente todas as funcionalidades implementadas, dando particular destaque aos problemas e soluções encontradas. Deve ser fácil ao leitor compreender o que foi feito e ter por isso capacidade de adaptar / modificar o código.

Conforme pode depreender do enunciado, **experimentação** e **análise** são parte fundamental deste trabalho prático. Assim, deve descrever de forma sucinta mas detalhada as experiências realizadas, os resultados obtidos, analisar os resultados e extrair conclusões.

O relatório deve conter informação relevante tanto da perspectiva do utilizador como do programador. Não deve ultrapassar as 20 páginas, formato A4. Todas as opções tomadas deverão ser devidamente justificadas e explicadas.

Modo de Entrega:

Entrega electrónica através do Inforestudante.

Data Limite: 22 de Maio de 2022

4 Bibliografia

- **Inteligência Artificial: Fundamentos e Aplicações**
Ernesto Costa, Anabela Simões
- **Artificial Intelligence: A Modern Approach**
Stuart Russel, Peter Norvig

Nuno Lourenço, Tiago Baptista, João Correia, Sérgio Rebelo e Pedro Silva – 2021/2022

Checklist

Nesta secção fornece-se uma breve checklist que visa minimizar as probabilidades de lacunas graves no trabalho e relatório. Importa no entanto salientar que esta checklist **não substitui** a validação das opções tomadas, que deverá ser efectuada preferencialmente durante as aulas Práticas Laboratoriais, **nem garante** a obtenção de uma classificação final positiva.

- Implementação:
 - Implementou operador(es) de recombinação?
 - Implementou operador(es) de mutação?
 - Implementou operador(es) de selecção de progenitores?
 - Implementou operador(es) de selecção de sobreviventes?
 - Os operadores de variação preservam a validade dos indivíduos?
 - Implementou o mecanismo de selecção por torneio?
 - Teve em conta o facto de ser um problema de maximização?
 - É possível parametrizar o algoritmo?
- Experimentação:
 - As experiências realizadas têm em conta a natureza estocástica da abordagem (i.e. efectua várias repetições da experiência usando os mesmos parâmetros e seeds aleatórias distintas)?
 - Tendo em conta as opções implementadas, os resultados realizadas permitem indicar:
 - * O melhor individuo para cada problema?
 - * A melhor taxa de mutação?
 - * O impacto do elitismo na performance do algoritmo?
 - * O impacto do tamanho do torneio na performance do algoritmo?
 - Tendo as experiências realizadas consegui evoluir agentes que permitam:
 - Terminar o dois cenários?
 - Qual o o tempo máximo que cada agente demora?
 - Qual o peso do veículo?
 - Qual o número de rodas do veículo?

- As respostas às perguntas anteriores constam do relatório? Estão devidamente justificadas e suportadas em resultados experimentais?
- No relatório, descreveu o que foi feito na meta 1 e meta 2?